NGS 데이턴분석 3강 Fastq 포맷 및 다운로드

출처: http://www.tinyurl.com/ngs2016

NGS 데이터

- NGS 시퀀싱 장비에서는 각 제조사마다 독특한 형식의 base call 파일을 생성
- 대부분의 분석 소프트웨어들이 공통으로 받아들이는 표준 서열 파일 형식은 fastq 포맷
- 시퀀싱 장비에 부속된 소프트웨어들은 서열 데이터를 fastq 형 식으로 변환하는 프로그램이 존재

FASTA format

FASTA is pronounced "fast A", and stands for "FAST-All", because it works with any alphabet, an extension of the original "FAST-P" (protein) and "FAST-N" (nucleotide) alignment tools.

An example of a multiple sequence FASTA file

Fasta sequence always start with this sign

>SEQUENCE 1

MTEITAAMVKELRESTGAGMMDCKNALSETNGDFDKAVQLLREKGLGKAAK KADRLAAEGVSVKVSDDFTAAMRPSYLSYEDLDMTFVENEYKALVAELEKE NEERRRLKDPNKPEHKQFASRKQLSDAILKEAEEKIKEELKAQGKPEKIWDNII PGKMNSFIADNSQLDSKLTLMGQFYVMDDKKTVEQVIAEKEKEFGGKIKIVEF ICFEVGEGLEKKTEDFAAEVAAQL

>SEQUENCE_2~

SATVSEINSETDFVARNDQFIALTKDTTAHIQSNSLQSVEELHSSTINGVKFEE YLKSQIATIGENLVVRRFATLKAGANGVVNGYIHTNGRVGVVIAAACDSAEVA SKSRDLLRQICMH

Fasta sequence will always have a sequence header

FASTAQ format

- Next-Generation Sequencing(NGS) data를 표현할 때 쓰는 표 준 format
- 일반적으로 fasta 형식의 파일은 염기 혹은 아미노산 서열을 표현할 때 사용하는데, 염기의 quality는 서열과 함께 저장하지 않고 별도의 파일에 저장
- Fastq는 서열과 quality를 한 파일에 저장하기 위해 고안된 형식

FASTAQ format

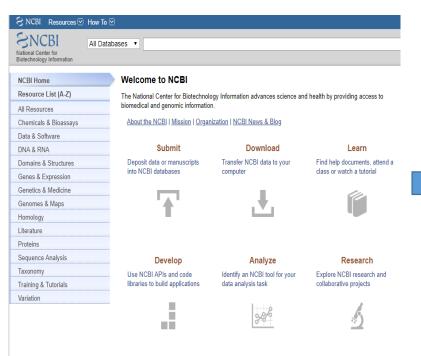
- 하나의 read에 대한 정보는 총 4줄
- 첫번째줄
 - ✔ Header 로 @로 시작
 - ✔등록번호 + 시퀀스장비명 + "flowcell ID:tile number:spotX좌표:spotY좌표" + sequence 길이 로 구성
- 두번째줄 : sequence data
- 세번째줄: +로 시작하고 첫번째 줄과 동 일
- 네번째줄 : sequence의 quality에 대한 정보

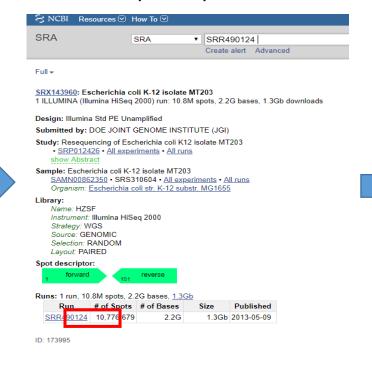
등록번호

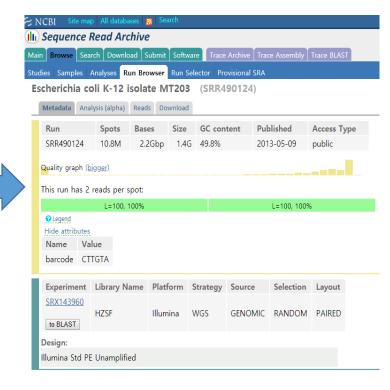
- NGS data를 사용한 연구 결과를 논문으로 출판하기 위해서는 NCBI/EBI/DDBJ 등과 같은 공공 데이터베이스에 등록
- NCBI는 SRR, EBI는 ERR, DDBJ는 DRR로 시작하는 등록번호를 부여
- "DRR00015"라는 NGS sequencing run의 데이터이며, 그 뒤에 따라오는 "1395"는 spot의 일련번호
- 일루미나 장비에서 직접 얻은 fastq 파일에는 위와 같은 등록번 호없음. 예) @HWUSI-EAS100R:6:73:941:1973#0/1

Fastq 파일 다운로드

- https://www.ncbi.nlm.nih.gov/
- All Databases -> SRA로 선택
- SRR490124 입력
- SRA Toolkit"이라는 소프트웨어 중에서 "fastq-dump"를 실행하여 다운로드할 것을 권장

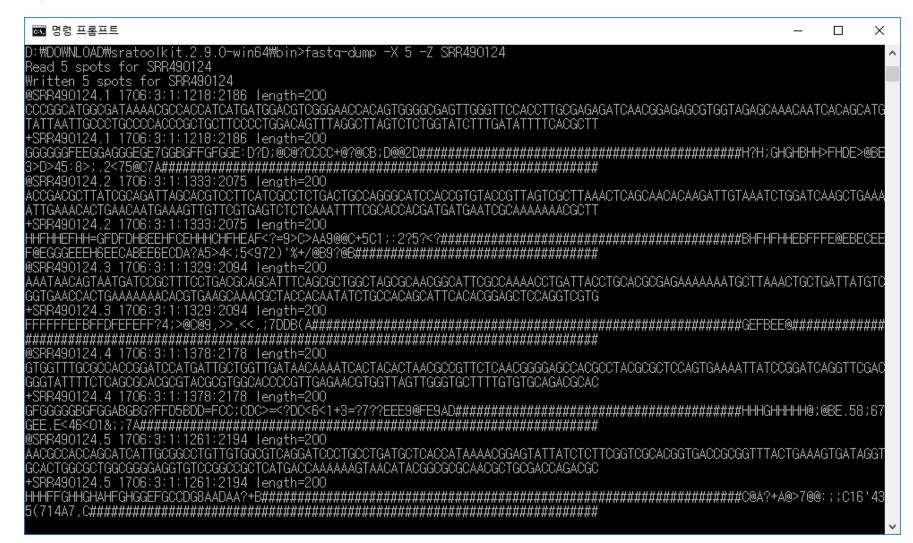






Fastq 파일 다운로드

fastq-dump -X 5 -Z SRR490124

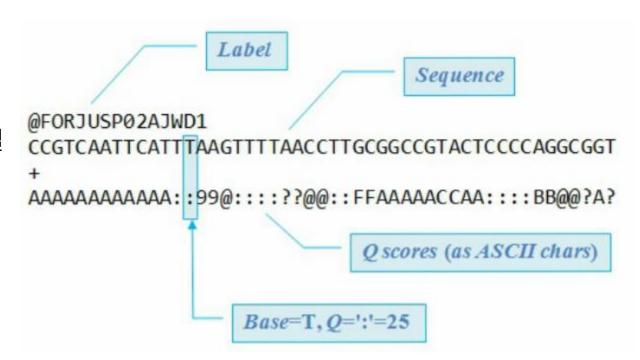


Base Call Quality

Sequence quality는 phred score를 나타냄

$$Q = -10log_{10}P$$

- P는 염기가 틀릴 확률
- 'A'가 아닐 확률이 10^-2라면, phred score는 20
- phred score가 크면 클수록 맞을 확률이 높고 틀릴 확률이 적은 것, 0 ~ 40사이에 존재
- Phred score를 그대로 쓰면 자리가 맞지 않음
- phred score를 표현하기 위해 ASCII code를 사용



ASCII code

- computer의 글자를 8개의 bit로 저장 하는 규약이다 (256개의 글자를 저장 할 수 있다)
- Phred score에 +33을 해준 값을 ASCII code로 바꿔서 fastq 파일에 저장
- Phred score 0 이면 ! 로 표시
- Phred score 40 이면 I 로 표시
- A의 Phred score는 얼마인가 ??

| | ASCII control characters | | | ASCII printable characters | | | | | | Extended ASCII characters | | | | | | | |
|-----|--------------------------|-----------------------|----|----------------------------|----|---|------------|---|-----|---------------------------|-----|-----|-----|----|-----|------|--|
| 00 | NULL | (Null character) | 32 | space | 64 | @ | 96 | | 128 | Ç | 160 | á | 192 | L | 224 | Ó | |
| 01 | SOH | (Start of Header) | 33 | ! | 65 | Α | 97 | a | 129 | ü | 161 | í | 193 | T | 225 | B | |
| 02 | STX | (Start of Text) | 34 | ** | 66 | В | 98 | b | 130 | é | 162 | Ó | 194 | т | 226 | Ô | |
| 03 | ETX | (End of Text) | 35 | # | 67 | C | 99 | С | 131 | â | 163 | ú | 195 | - | 227 | Ò | |
| 04 | EOT | (End of Trans.) | 36 | \$ | 68 | D | 100 | d | 132 | ä | 164 | ñ | 196 | - | 228 | ő | |
| 05 | ENQ | (Enquiry) | 37 | % | 69 | E | 101 | е | 133 | à | 165 | Ñ | 197 | + | 229 | Õ | |
| 06 | ACK | (Acknowledgement) | 38 | & | 70 | F | 102 | f | 134 | å | 166 | a | 198 | ä | 230 | μ | |
| 07 | BEL | (Bell) | 39 | • | 71 | G | 103 | g | 135 | ç | 167 | 0 | 199 | Ã | 231 | þ | |
| 08 | BS | (Backspace) | 40 | (| 72 | Н | 104 | h | 136 | ê | 168 | i | 200 | L | 232 | Þ | |
| 09 | HT | (Horizontal Tab) | 41 |) | 73 | 1 | 105 | Í | 137 | ë | 169 | (8) | 201 | F | 233 | Ú | |
| 10 | LF | (Line feed) | 42 | * | 74 | J | 106 | j | 138 | è | 170 | 7 | 202 | 1 | 234 | Û | |
| 11 | VT | (Vertical Tab) | 43 | + | 75 | K | 107 | k | 139 | ï | 171 | 1/2 | 203 | TE | 235 | Ù | |
| 12 | FF | (Form feed) | 44 | , | 76 | L | 108 | 1 | 140 | î | 172 | 1/4 | 204 | - | 236 | ý | |
| 13 | CR | (Carriage return) | 45 | - | 77 | M | 109 | m | 141 | ì | 173 | i | 205 | = | 237 | Ý | |
| 14 | SO | (Shift Out) | 46 | | 78 | N | 110 | n | 142 | Ä | 174 | 40 | 206 | # | 238 | - | |
| 15 | SI | (Shift In) | 47 | 1 | 79 | 0 | 111 | 0 | 143 | Â | 175 | 39 | 207 | n | 239 | | |
| 16 | DLE | (Data link escape) | 48 | 0 | 80 | P | 112 | p | 144 | É | 176 | 1 | 208 | ð | 240 | = | |
| 17 | DC1 | (Device control 1) | 49 | 1 | 81 | Q | 113 | q | 145 | æ | 177 | 200 | 209 | Đ | 241 | ± | |
| 18 | DC2 | (Device control 2) | 50 | 2 | 82 | R | 114 | r | 146 | Æ | 178 | | 210 | Ê | 242 | | |
| 19 | DC3 | (Device control 3) | 51 | 3 | 83 | S | 115 | S | 147 | ô | 179 | T | 211 | Ë | 243 | 3/4 | |
| 20 | DC4 | (Device control 4) | 52 | 4 | 84 | T | 116 | t | 148 | Ö | 180 | - | 212 | È | 244 | 1 | |
| 21 | NAK | (Negative acknowl.) | 53 | 5 | 85 | U | 117 | u | 149 | ò | 181 | Á | 213 | 1 | 245 | § | |
| 22 | SYN | (Synchronous idle) | 54 | 6 | 86 | V | 118 | V | 150 | û | 182 | Â | 214 | ĺ | 246 | ÷ | |
| 23 | ETB | (End of trans, block) | 55 | 7 | 87 | W | 119 | w | 151 | ù | 183 | À | 215 | î | 247 | | |
| 24 | CAN | (Cancel) | 56 | 8 | 88 | X | 120 | X | 152 | ÿ | 184 | 0 | 216 | Ï | 248 | 0 | |
| 25 | EM | (End of medium) | 57 | 9 | 89 | Y | 121 | У | 153 | Ö | 185 | 1 | 217 | ١ | 249 | ** | |
| 26 | SUB | (Substitute) | 58 | : | 90 | Z | 122 | Z | 154 | Ü | 186 | | 218 | г | 250 | | |
| 27 | ESC | (Escape) | 59 | ; | 91 |] | 123 | { | 155 | Ø | 187 | 7 | 219 | | 251 | 1 | |
| 28 | FS | (File separator) | 60 | < | 92 | i | 124 | ì | 156 | £ | 188 | J | 220 | | 252 | 3 | |
| 29 | GS | (Group separator) | 61 | = | 93 | 1 | 125 | } | 157 | Ø | 189 | ¢ | 221 | - | 253 | 2 | |
| 30 | RS | (Record separator) | 62 | > | 94 | ۸ | 126 | ~ | 158 | × | 190 | ¥ | 222 | i | 254 | | |
| 31 | US | (Unit separator) | 63 | ? | 95 | | A STATE OF | | 159 | f | 191 | 7 | 223 | | 255 | nbst | |
| 127 | DEL | (Delete) | | | | - | | | | , | | -1 | | | | | |